

UNIVERSIDADE FEDERAL DE GOIÁS
INSTITUTO DE INFORMÁTICA

LAYS DE FREITAS MELO

Estudo e Definição de um Modelo de Predição de Óbitos no Contexto da COVID-19

Goiânia
2023

UNIVERSIDADE FEDERAL DE GOIÁS
INSTITUTO DE INFORMÁTICA

**AUTORIZAÇÃO PARA PUBLICAÇÃO DE TRABALHO DE
CONCLUSÃO DE CURSO EM FORMATO ELETRÔNICO**

Na qualidade de titular dos direitos de autor, **AUTORIZO** o Instituto de Informática da Universidade Federal de Goiás – UFG a reproduzir, inclusive em outro formato ou mídia e através de armazenamento permanente ou temporário, bem como a publicar na rede mundial de computadores (*Internet*) e na biblioteca virtual da UFG, entendendo-se os termos “reproduzir” e “publicar” conforme definições dos incisos VI e I, respectivamente, do artigo 5º da Lei nº 9610/98 de 10/02/1998, a obra abaixo especificada, sem que me seja devido pagamento a título de direitos autorais, desde que a reprodução e/ou publicação tenham a finalidade exclusiva de uso por quem a consulta, e a título de divulgação da produção acadêmica gerada pela Universidade, a partir desta data.

Título: Estudo e Definição de um Modelo de Predição de Óbitos no Contexto da COVID-19

Autor(a): Lays de Freitas Melo

Goiânia, 21 de Agosto de 2023.

Lays de Freitas Melo – Autor

Jacson Rodrigues Barbosa – Orientador

LAYS DE FREITAS MELO

Estudo e Definição de um Modelo de Predição de Óbitos no Contexto da COVID-19

Trabalho de Conclusão apresentado à Coordenação do Curso de Computação do Instituto de Informática da Universidade Federal de Goiás, como requisito parcial para obtenção do título de Bacharel em Computação.

Área de concentração: Otimização.

Orientador: Prof. Jacson Rodrigues Barbosa

Goiânia
2023

LAYS DE FREITAS MELO

Estudo e Definição de um Modelo de Predição de Óbitos no Contexto da COVID-19

Trabalho de Conclusão apresentado à Coordenação do Curso de Computação do Instituto de Informática da Universidade Federal de Goiás como requisito parcial para obtenção do título de Bacharel em Computação, aprovada em 21 de Agosto de 2023, pela Banca Examinadora constituída pelos professores:

Prof. Jacson Rodrigues Barbosa
Instituto de Informática – UFG
Presidente da Banca

Prof. Elias Batista Ferreira
Instituto de Informática – UFG

Todos os direitos reservados. É proibida a reprodução total ou parcial do trabalho sem autorização da universidade, do autor e do orientador(a).

Lays de Freitas Melo

Graduanda em Ciência da Computação na UFG - Universidade Federal de Goiás. Durante sua graduação, foi monitória de Fundamentos da Matemática para Computação e Lógica Matemática além de pesquisadora do CNPq em um trabalho de iniciação científica voluntária sobre Conjuntos Dominantes Independentes Abertos no Produto Lexicográfico de Alguns Grafos, no Instituto de Informática da UFG.

Dedico este trabalho a minha família.

Agradecimentos

Agradeço a minha família pela direção que me ajudou a seguir os meus objetivos, ao meu orientador pela paciência ao longo do desenvolvimento desse trabalho, a Deus pela fé que nunca me deixou desistir e a Universidade Federal de Goiás que foi onde obtive felizes dias da minha vida.

"Sem dados você é apenas mais uma pessoa com uma opinião"

William Edwards Deming,

.

Resumo

de Freitas Melo, Lays. **Estudo e Definição de um Modelo de Predição de Óbitos no Contexto da COVID-19**. Goiânia, 2023. 42p. Relatório de Graduação. Instituto de Informática, Universidade Federal de Goiás.

Neste estudo foi realizado um mapeamento sistemático com o objetivo de encontrar modelos preditivos de óbitos a medida que a vacinação foi sendo introduzida na população. Nos artigos analisados foram encontrados vários modelos como SIR(Suscetível - Infecado - Removido) e suas variações, assim como modelos de RN (Redes Neurais) e suas modificações. Além disso, foi observado através de dados do site do DataSUS o avanço da vacinação na Região Centro-Oeste e foi proposto um modelo de predição baseado no algoritmo LSTM com dados do Estado de Goiás.

Palavras-chave

COVID-19, predição de morte, monografia

Abstract

de Freitas Melo, Lays. **In this study, a systematic mapping was accomplished in order to find predictive models of deaths as vaccination was introduced in the population. In the analyzed articles, modified SIR(Suscetible - Infected - Removed) models and variations, as well as NN(Neural Networks) models and modifications. In addition, was observed through data from DataSus website the advancement of vaccination in the Midwest region and a prediction model based on the LSTM algorithm with data from the State of Goiás was proposed..** Goiânia, 2023. 42p. Relatório de Graduação. Instituto de Informática, Universidade Federal de Goiás.

Keywords

COVID-19, death prediction, monography

Sumário

Lista de Figuras	11
Lista de Tabelas	12
Lista de Algoritmos	13
Lista de Códigos de Programas	14
1 Introdução	15
1.1 Objetivos	15
1.2 Metodologia	16
1.3 Organização do trabalho	16
2 Aspectos gerais de ciências de dados	18
2.1 O que é ciência de dados?	18
2.2 Algoritmos de modelagem	19
2.2.1 Algoritmos de aprendizado de máquina	19
2.2.2 Algoritmos de Aprendizagem Supervisionada	20
Algoritmos de classificação	20
Algoritmos de regressão	20
2.2.3 Deep learning	20
RNN - Recurrent Neural Network	21
LSTM - Long Short Term Memory	21
CNN - Convolutional Neural Network	21
2.3 COVID-19 no centro-oeste brasileiro: um estudo de caso de ciência de dados	22
3 Mapeamento Sistemático	31
3.1 Objetivo e Questões de Pesquisa	31
3.2 Estratégia de Busca (String de Busca)	31
3.3 Identificação e Seleção dos Estudos Primários	32
3.3.1 Critérios de Inclusão	32
3.3.2 Critérios de Exclusão	32
3.4 Síntese dos Dados	33
3.4.1 QP1. Quais modelos preditivos são utilizados para prever o número de óbitos por COVID-19 no contexto da introdução da vacinação?	33
3.4.2 QP2. Quais são os tipos de informações utilizadas para apoiar a predição?	34

4	Modelo de predição de óbitos proposto	36
4.1	Descrição do dataset utilizado	36
4.2	Descrição do modelo aplicado	36
4.3	Avaliação experimental	37
5	Conclusão	39
5.1	Contribuições do trabalho	39
5.2	Trabalhos Futuros	40
5.3	Disponibilidade dos Códigos e Dados	40
	Referências Bibliográficas	41

Lista de Figuras

2.1	Ciclo de Vida do Dado	19
2.2	Ciclo de vida da Ciência de Dados	19
2.3	Exemplos de algoritmos de aprendizagem supervisionada	20
2.4	Quantidade de vacinas aplicadas por mês no Estado de Goiás.	23
2.5	Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Estado de Goiás.	23
2.6	Quantidade de pessoas vacinadas na 1 ^o , 2 ^a e dose única no Estado de Goiás.	24
2.7	Quantidade de óbitos mensal no Estado de Goiás.	24
2.8	Quantidade de vacinas aplicadas por mês no Estado de Mato Grosso.	25
2.9	Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Estado de Mato Grosso.	25
2.10	Quantidade de pessoas vacinadas na 1 ^o , 2 ^a e dose única no Estado de Mato Grosso.	26
2.11	Quantidade de óbitos mensal no Estado de Mato Grosso.	26
2.12	Quantidade de vacinas aplicadas por mês no Estado de Mato Grosso do Sul.	27
2.13	Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Estado de Mato Grosso do Sul.	27
2.14	Quantidade de pessoas vacinadas na 1 ^o , 2 ^a e dose única no Estado de Mato Grosso do Sul.	28
2.15	Quantidade de óbitos mensal no Estado de Mato Grosso do Sul.	28
2.16	Quantidade de vacinas aplicadas por mês no Distrito Federal.	29
2.17	Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Distrito Federal.	29
2.18	Quantidade de pessoas vacinadas na 1 ^o , 2 ^a e dose única no Distrito Federal.	30
2.19	Quantidade de óbitos mensal no Distrito Federal.	30
4.1	Gráfico gerado na fase de treinamento da LSTM	37
4.2	Gráfico gerado na fase de validação da LSTM	38
4.3	Gráfico gerado na fase de predição da LSTM	38

Lista de Tabelas

2.1	RNNs, LSTMs e CNNs	22
3.1	Parâmetros usados no modelo CNN no [2]	34
3.2	Parâmetros usados nos modelos RNN e LSTM no [2]	34
4.1	Parâmetros usados no modelo de predição LSTM	37

Lista de Algoritmos

Lista de Códigos de Programas

Introdução

O COVID-19 teve um impacto significativo em todo o mundo, resultando em hospitalizações e óbitos em grande escala. A declaração da Organização Mundial da Saúde (OMS) em março de 2020 reconheceu a gravidade da situação e a necessidade de ação global coordenada. No Brasil, o país foi amplamente afetado pela pandemia, com altos números de casos e óbitos. De acordo com a publicação "Violações dos direitos humanos no Brasil: Denúncias e Análises no Contexto da Covid-19" no site do Conselho Nacional de Saúde pelo Ministério da Saúde, vários fatores, como a desigualdade social e regional, são responsáveis por essa quantidade de casos e óbitos. Estudos mostraram que a vacinação desempenhou um papel crucial na redução de óbitos relacionados à COVID-19, oferecendo proteção significativa, especialmente entre os idosos. As vacinas têm sido eficazes na prevenção de casos graves e na proteção da vida das pessoas, contribuindo para o controle da pandemia no Brasil.

1.1 Objetivos

Durante a execução deste trabalho, estabelecemos uma série de objetivos para aprofundar nosso entendimento sobre a relação entre vacinação e óbitos, assim como para destacar a importância da vacinação. Nossos principais objetivos são:

1. Investigar o estado da arte dos casos de óbitos por COVID-19 após o início da vacinação.
2. Explorar base de dados com informações de pacientes com COVID-19 nos estados brasileiros.
3. Predizer casos de óbitos por COVID-19 no Brasil utilizando uma estratégia proposta no estado da arte.

Ao atingir esses objetivos, esperamos contribuir para o avanço do conhecimento científico sobre a eficácia da vacinação na redução dos óbitos decorrentes da COVID-19. Nossos resultados poderão fornecer informações valiosas para os responsáveis pela

saúde pública, decisores políticos e profissionais da área, ajudando a embasar estratégias efetivas no combate à pandemia.

1.2 Metodologia

Para que fosse possível atender os objetivos do presente trabalho, as seguintes etapas foram definidas:

1. Realizar um mapeamento sistemática abrangente da literatura científica existente sobre modelos de predição envolvendo vacinação e óbitos. Esse mapeamento nos permitirá analisar as abordagens utilizadas, as variáveis consideradas e as metodologias empregadas na previsão de óbitos relacionados à COVID-19 após o início da vacinação.
2. Coletar dados da região Centro-Oeste do Brasil, específicos para cada estado, e extrair informações relevantes sobre a vacinação e os óbitos relacionados à COVID-19. Esses dados serão fundamentais para uma análise detalhada do impacto da vacinação nos índices de mortalidade em nível estadual.
3. Desenvolver um modelo de predição de óbitos utilizando o algoritmo LSTM (Long Short-Term Memory). Esse modelo nos permitirá simular um cenário hipotético em que a população não tenha sido vacinada, possibilitando uma análise do impacto potencial da vacinação na redução dos óbitos relacionados à COVID-19. Serão considerados diferentes níveis de cobertura vacinal para avaliar seu efeito nos índices de mortalidade.

1.3 Organização do trabalho

Este trabalho está organizado da seguinte forma: no Capítulo 2 é apresentado uma visão geral dos conceitos relacionados com o trabalho, que são essenciais para o entendimento básico do leitor, introduzindo termos científicos da área. Além disso, são apresentados gráficos que detalham o estudo do caso da Covid-19 na Região Centro-Oeste do Brasil, com informações sobre a distribuição mensal de vacinas e os tipos de dose administradas.

No Capítulo 3 é apresentado o protocolo do mapeamento sistemático de artigos que abordam a predição de óbitos relacionados à Covid-19 no contexto da vacinação.

A descrição do modelo de predição está presente no Capítulo 4. São apresentadas informações sobre a base de dados utilizada no algoritmo, a seleção do modelo de predição e seus parâmetros. Além disso, os gráficos que evidenciam os resultados da

avaliação desse algoritmo LSTM também se encontram nesse capítulo. Por fim, as conclusões são encontradas no Capítulo 5.

Aspectos gerais de ciências de dados

2.1 O que é ciência de dados?

A ciência de dados é uma ciência nova, apesar da expressão *Data Science* ser utilizada desde 1960. Ela é responsável por todo o ciclo de vida do dado, desde a coleta até o descarte, obtendo assim conhecimento e informação sobre ele ao longo deste ciclo.

Com o intuito de obter resultados para tomadas de decisões, e por esses dados coletados geralmente serem volumosos e extraídos de várias fontes, é utilizado ferramentas, técnicas, modelos e processos. Estes meios comumente são derivados de outras áreas do conhecimento, como por exemplo, mineração de dados, estatística, *big data*.

Um exemplo de processo comum na área de dados é o pipeline chamado ETL (Extrair, Transformar e Carregar). Esse pipeline move e transforma informações de diferentes fontes de dados em um ambiente de armazenamento centralizado. O ETL é extensamente utilizado na carreira de dados.

O cientista de dados é responsável por cuidar de todo o ciclo de vida da ciência de dado. De acordo com a figura 2.2 o ciclo cobre desde o entendimento do problema, passando pela coleta, processamento e exploração dos dados, seguido da comunicação dos resultados e feedback [1]. Esse profissional pode ter origem acadêmica ou empresarial e é cobrado dele uma visão sistemática, conhecimentos matemáticos, que podem ser de estatística ou de álgebra linear, além de linguagens de software. Ele consegue transformar o dado, que é a matéria-prima crua, em informação, onde o dado é analisado e atribuído um significado, e a informação em conhecimento, pois foi incumbido uma interpretação que foi entendida e aplicada para um fim.




Figura 2.1: *Ciclo de Vida do Dado*




Figura 2.2: *Ciclo de vida da Ciência de Dados*

2.2 Algoritmos de modelagem

2.2.1 Algoritmos de aprendizado de máquina

Assim como os bebês aprendem através da repetição de palavras por seus pais quando estão aprendendo a falar, as máquinas aprendem através da repetição também. Elas possuem algoritmos com um grande volume de dados e algumas camadas de treinamento. Esses algoritmos são os de aprendizado de máquina (*machine learning*).

Há 3 categorias de algoritmos, aprendizagem supervisionada, aprendizagem não supervisionada e aprendizagem por reforço. Cada uma é utilizada com tipos de dados e objetivos diferentes.

2.2.2 Algoritmos de Aprendizagem Supervisionada

Esse algoritmo é alimentado com pares de entradas e saídas rotuladas e depois da fase de treinamento e teste, ele determina uma forma de prever as saídas baseando-se nas entradas fornecidas.

Algoritmos de classificação

Quando os dados fornecidos são dados discretos, o aprendizado supervisionado age como um classificador, reconhecendo padrões desses dados e predizendo categorias para cada um deles.

Algoritmos de regressão

Quando os dados fornecidos são dados contínuos, o algoritmo estuda as relações entre esses dados e é utilizado para prever resultados.




Figura 2.3: Exemplos de algoritmos de aprendizagem supervisionada

2.2.3 Deep learning

Os algoritmos deep learning fazem parte de um subconjunto dos algoritmos de machine learning. Eles se baseiam em redes neurais, onde conseguem através de várias camadas de neurônios uma aprendizagem profunda sem a intervenção humana, simulando um cérebro humano.

A vantagem da utilização da aprendizagem profunda é a identificação de padrões com um maior volume de dados, onde eles podem ser mais complexos e também não precisam ser estruturados, suporte a imagens e vozes.

Há 3 arquiteturas de redes neurais abordadas nesse trabalho, redes neurais recorrentes (RNN), memória de curto prazo longa (LSTM) e redes neurais convolucionais (CNN).

RNN - Recurrent Neural Network

Além dos dados da camada anterior, os neurônios da rede neural recorrente também recebem o resultado da operação matemática que eles mesmos realizaram no período temporal anterior. Dessa forma, as RNNs consideram uma dependência temporal entre os dados de entrada.

LSTM - Long Short Term Memory

As LSTMs são consideradas evoluções das RNNs, por resolver um problema comum nas redes neurais recorrentes, os gradientes que explodem ou desaparecem, que fazem com que a relação temporal que a rede deve aprender se perca com o tempo. É resolvido pelos neurônios das redes LSTM conseguem isso mantendo uma célula exclusiva para o armazenamento e fluxo da memória, além de portões do tipo entrada, saída e esquecimento, que controlam esse fluxo.

CNN - Convolutional Neural Network

Utiliza aprendizagem supervisionada. Nas camadas de convolução, os filtros são aplicados para destacar padrões locais nos dados e reduzir sua dimensão. Os resultados dos filtros são combinados por operações de pooling. Nas camadas mais profundas, espera-se que os dados de menor dimensão ainda contenham informações relevantes sobre os padrões locais. Em seguida, os dados passam por uma estrutura de FFN (Feedforward Neural Network) para realizar a tarefa de classificação.

Arquiteturas	Natureza dos Dados	Tarefas Realizadas
RNN	Adequadas para processar dados sequenciais, como sequências de texto.	Tradução automática, análise de sentimentos, classificação de textos.
LSTM	As LSTMs são uma variação das RNNs projetadas para lidar com sequências de dados de série temporal, como dados climáticos, dados financeiros ou registros de atividades	Tradução automática, análise de sentimentos, classificação de textos e modelar dependências de longo prazo em sequências de dados de séries temporais.
CNN	Amplamente utilizadas em tarefas de visão computacional, onde os dados de entrada são imagens representadas em formato de grade bidimensional.	Classificação de imagens e detecção de objetos.

Tabela 2.1: *RNNs, LSTMs e CNNs*

2.3 COVID-19 no centro-oeste brasileiro: um estudo de caso de ciência de dados

Nesta seção, apresenta-se avaliações exploratórias dos dados coletados a partir das fontes Datasus e Coronavírus Brasil. As Figuras 2.4, 2.8, 2.12 e 2.16 exibem as quantidades de vacinas aplicadas por Estado durante o período de Janeiro de 2021 a Junho de 2022, incluindo a soma de todas as doses administradas. Enquanto as Figuras 2.5, 2.9, 2.13 e 2.17 proporcionam uma diferenciação dessas quantidades, especificamente pelas doses administradas no mesmo intervalo temporal conforme mencionado anteriormente.

Ao analisar esses gráficos, podemos concluir que a maioria das vacinas foi administrada no segundo semestre de 2021, evidenciando picos de vacinação nesse período para os quatro cenários abordados.

No entanto, para uma análise mais refinada das doses individuais, ou seja, primeira, segunda doses e doses de reforço, as Figuras 2.3, 2.10, 2.14 e 2.18 enfatizam essa distinção. Esses gráficos permitem afirmar que, nos três Estados avaliados e no Distrito Federal, a grande maioria da população recebeu apenas até a segunda dose da vacina. Ao comparar com as doses adicionais e de reforço, a discrepância é notável, destacada nos três primeiros gráficos de cada Estado e do Distrito Federal.

Por fim, ao compararmos os gráficos de vacinação com os de óbitos, 2.7, 2.11, 2.15 e 2.19, podemos constatar que, após o pico de vacinação no segundo semestre de 2021, houve uma queda significativa no número de óbitos, uma tendência que se manteve até o primeiro semestre de 2022. O código fonte está disponível no GitHub.

Estado de Goiás




Figura 2.4: *Quantidade de vacinas aplicadas por mês no Estado de Goiás.*




Figura 2.5: *Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Estado de Goiás.*




Figura 2.6: *Quantidade de pessoas vacinadas na 1ª, 2ª e dose única no Estado de Goiás.*




Figura 2.7: *Quantidade de óbitos mensal no Estado de Goiás.*

Estado de Mato Grosso




Figura 2.8: *Quantidade de vacinas aplicadas por mês no Estado de Mato Grosso.*




Figura 2.9: *Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Estado de Mato Grosso.*




Figura 2.10: *Quantidade de pessoas vacinadas na 1ª, 2ª e dose única no Estado de Mato Grosso.*



Figura 2.11: *Quantidade de óbitos mensal no Estado de Mato Grosso.*

Estado de Mato Grosso do Sul




Figura 2.12: *Quantidade de vacinas aplicadas por mês no Estado de Mato Grosso do Sul.*




Figura 2.13: *Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Estado de Mato Grosso do Sul.*




Figura 2.14: *Quantidade de pessoas vacinadas na 1ª, 2ª e dose única no Estado de Mato Grosso do Sul.*



Figura 2.15: *Quantidade de óbitos mensal no Estado de Mato Grosso do Sul.*

Distrito Federal




Figura 2.16: *Quantidade de vacinas aplicadas por mês no Distrito Federal.*




Figura 2.17: *Quantidade de vacinas aplicadas por tipo de dose desde o início da vacinação naquele Estado até junho de 2022 no Distrito Federal.*




Figura 2.18: *Quantidade de pessoas vacinadas na 1ª, 2ª e dose única no Distrito Federal.*




Figura 2.19: *Quantidade de óbitos mensal no Distrito Federal.*

Mapeamento Sistemático

Nesse capítulo é apresentado o mapeamento sistemático, que foi organizado em três etapas (planejamento, condução e publicação dos resultados) conforme proposto por [8]. Essas três etapas foram realizadas na ferramenta Parsifal

O planejamento é a parte na qual é definido o protocolo, nessa etapa definimos os objetivos do estudo, quais são as questões de pesquisa, as *keywords* e a *string de busca* para encontrar os artigos, critérios de inclusão e exclusão também são definidos aqui.

Na condução é realizada a seleção dos trabalhos baseado no protocolo construído na etapa anterior, baseado nos critérios de inclusão e exclusão. Após a seleção os dados são extraídos e sintetizados por meio de um formulário de extração de dados.

Por fim na publicação de resultados é feita a escrita desse mapeamento sistemático.

3.1 Objetivo e Questões de Pesquisa

O principal objetivo desse estudo foi identificar quais modelos preditivos de óbito foram utilizados em outros trabalhos em relação ao avanço da vacinação na população. As questões de pesquisa (QP) que visamos responder com o intuito de atender esse objetivo foram:

QP1. Quais modelos preditivos são utilizados para prever o número de óbitos por COVID-19 no contexto da introdução da vacinação?

QP2. Quais são os tipos de informações utilizadas para apoiar a predição?

3.2 Estratégia de Busca (String de Busca)

Nesta seção mostra a *string de busca* utilizada com o intuito de obter os melhores artigos, para assim obter uma visão ampla do tópico abordado no estudo:

("death prediction") AND ("covid-19") AND ("vaccination")

Como resultado inicial foram encontrados 64 artigos, distribuídos em 3 bases bibliográficas digitais sendo elas: ACM Digital Library com 43 artigos (67,2%), IEEE com 11 artigos (17,2%), Science@Direct com 10 artigos (15,6%).

Para auxiliar no gerenciamento e organização desde a busca até a extração de dados dos artigos selecionados, utilizamos a ferramenta virtual Parsifal.

3.3 Identificação e Seleção dos Estudos Primários

Esta seção descreve o método utilizado para selecionar os estudos relevantes para responder às questões de pesquisa deste mapeamento sistemático. Todos os 64 artigos foram analisados e categorizados de acordo com os seguintes critérios.

3.3.1 Critérios de Inclusão

Como se trata de um mapeamento inicial para o tópico escolhido apenas um critério, mais amplo, foi escolhido como critério de inclusão.

1. Quais são os tipos de informações utilizadas para apoiar a predição?

3.3.2 Critérios de Exclusão

Foram escolhidos 5 critérios de exclusão para o tópico abordado.

1. Não aborda a COVID-19.
2. Não aborda modelos preditivos de óbito.
3. Não aborda vacinação contra COVID-19.
4. Não é um estudo primário.
5. Texto completo indisponível.

Se um texto se encaixa ao menos em uma categoria dessas enumeradas acima ele será excluído da pesquisa e categorizado de acordo com o motivo de sua exclusão. Caso contrário ele será selecionado para a extração de dados.

Nesse estudo 64 artigos foram escolhidos de acordo com a *string de busca* e 1 foi eliminado por ser duplicata, sobrando assim 63 artigos. Com a leitura do resumo de cada artigo, aplicando os critérios de inclusão e exclusão, 57 trabalhos foram eliminados por se encaixarem em algum dos critérios de exclusão, restando assim 6 artigos aceitos.

Desses 57 trabalhos excluídos, 27 (47,3%) foram excluídos por não abordarem modelos preditivos de óbito, 19 (33,3%) por não terem texto completo disponível, 9 (15,8%) por não abordarem vacinação contra COVID-19, 1 (1,8%) por não abordar COVID-19 e finalmente 1 (1,8%) por não ser um estudo primário.

3.4 Síntese dos Dados

Após a etapa de extração de dados foi realizada uma síntese deles com o objetivo de responder as questões de pesquisa proposta nesse estudo.

3.4.1 QP1. Quais modelos preditivos são utilizados para prever o número de óbitos por COVID-19 no contexto da introdução da vacinação?

Os modelos encontrados nos artigos aceitos são:

- **SIRUCQHE (Susceptible - Infected - Removed - Unsusceptible - Contagious - Quarantined - Hospitalized - Extinct):** que traduzindo significa Suscetível-Infectado-Removido-Insusceptível-Contagioso-Em Quarentena-Hospitalizado-Extinto. Esse modelo é composto por 8 equações com diferenças na variação do tempo de fluxos individuais entre vários compartimentos [9];
- **SEIAQFR (Susceptible - Exposed - Infected - Asymptomatic - Quarantined - Fatal - Recovered):** que significa respectivamente, Suscetível-Exposto-Infectado-Assintomático-Em Quarentena-Fatal-Recuperado [5].;
- **SIR (Susceptible - Infected - Recovered):** que traduzido significa respectivamente, Suscetível-Infectado-Recuperado com parâmetros de variação de tempo [4];
- **DNN (Fully Connected Deep Neural Network):**, traduzindo significa rede neural profunda totalmente conectada. Ela não requer nenhuma suposição sobre a entrada para ser usada, é uma aplicação genérica de uma rede neural artificial [3];
- **LSTM (Long Short-Term Memory):**, conhecida como memória de curto longo prazo é uma arquitetura de rede recorrente combinada com um algoritmo de aprendizado baseado em gradientes. Uma vantagem do modelo LSTM é sua habilidade de aprender mesmo com ruídos, ou sequência de entradas incompreensíveis sem perda de eficiência. Há dois artigos que utilizam esse modelo preditivo [2] e [3];
- **TM (Transformer Model):**, modelo transformador é um modelo DNN que lida com pontos de entrada de dados sequenciais usados na representação de entrada [3];
- **RNN (Recurrent Neural Network):** ou rede neural recorrente é o mais simples modelo de aprendizado profundo que consegue lembrar de informações passadas e

realizar predições [2];

- **CNN (Convolutional Neural Network):** a Rede Neural Convolutacional é um modelo de aprendizado profundo que trabalha bem com imagens, textos e dados numéricos [2];
- **ANN (Multi-Layer Perceptron Artificial Neural Network):** A arquitetura nesse modelo possui um conjunto de neurônios na camada de entrada, uma ou mais camadas escondidas, e apenas uma camada de saída. Possui apenas um neurônio na camada de saída, a estimativa de casos e mortes foi realizada em redes separadas. A arquitetura *feed-forward* da ANN foi utilizada, nela os dados fluem da entrada até a saída sem nenhum *feedback* [7].

3.4.2 QP2. Quais são os tipos de informações utilizadas para apoiar a predição?

No artigo [2] há as seguintes informações:

Parâmetros	Valores
Números de camadas de convolução	2
Números de camadas de max-pooling	1
Número de camadas completamente conectadas	3
Número de nós em camadas completamente conectadas	100, 50, 1
Número de filtros em cada camada de convolução	100, 64
Tamanho do kernel/filtro em cada camada de convolução	3
Tamanho da pool na camada max-pooling	3
Strides	2
Função de ativação em camadas de convolução	Relu
Épocas	100

Tabela 3.1: Parâmetros usados no modelo CNN no [2]

Parâmetros	Valores
Números de camadas	3
Números de nós em cada camada	128, 100, 50
Números de camadas completamente conectadas	2
Número de nós em camadas completamente conectadas	50, 1
Função de ativação	Relu
Épocas	100

Tabela 3.2: Parâmetros usados nos modelos RNN e LSTM no [2]

No artigo [3] são utilizadas essas informações nos modelos de predição : pessoas vacinadas, pessoas totalmente vacinadas, pessoas vacinadas por cem, pessoas totalmente vacinadas por cem, extrema pobreza, instalações para lavar as mãos, internações semanais no hospital, internações semanais no hospital por milhão, pacientes na UTI por milhão, internações semanais na UTI por milhão, internações semanais na UTI, pacientes hospitalizados por milhão, pacientes hospitalizados, pacientes de UTI, novas vacinas, total vacinações por cem, vacinações totais, novas vacinações suavizadas por milhão, novas vacinações suavizadas e novas mortes por milhão.

No artigo [5] utiliza os seguintes parâmetros em seu modelo β (frequência média de contato), α (taxa de exposição se torna infecciosa), γ (taxa de sintomáticos são movidos para o estado de quarentena no hospital ou em casa), ϕ (taxa de pessoas assintomáticas também contribuem para o grupo de infectados sintomáticos desenvolvendo sintomas após $(1/\phi)$ dias), θ (taxa de recuperação após o tratamento), δ (taxa de mortalidade/fatalidade).

Modelo de predição de óbitos proposto

4.1 Descrição do dataset utilizado

Os dados utilizados no modelo de predição são os mesmos utilizados nos gráficos da seção 2 deste trabalho, porém com modos de preparos diferentes.

Os dados foram retirados do site *OpenDataSus* e do site Coronavírus Brasil. No *OpenDataSus* está concentrado os conjuntos de dados do governo que foram coletados através da organização Ministério da Saúde em conjunto com as secretarias de cada estado, já o site Coronavírus Brasil é alimentado com as mesmas informações, porém nele o conjunto de dados já vem com menos dados e um pré-processamento já realizado.

Para este trabalho os dados de vacinação foram coletados do conjunto de dados "Campanha Nacional de Vacinação contra Covid-19" presente no *OpenDataSus*, e a quantidade de casos novos diários e de óbitos foram coletados do site Coronavírus Brasil.

Os dados utilizados dos dois conjuntos de dados são do período de janeiro de 2020 até dezembro de 2022. Foi realizado um pré-processamento dos dados onde houve substituição dos dados *NAN* para 0 (zero), e a condensação das datas por mês e ano. Assim são o total de 36 linhas (como citado anteriormente do dia 01/01/2020 até 31/12/2022) e 3 colunas (quantidade de vacinados, quantidade de casos novos e quantidade de óbitos).

Os dados analisados na criação dos gráficos presentes na seção 2 foram relativos a Região Centro-Oeste, e no modelo de predição ao Estado de Goiás.

4.2 Descrição do modelo aplicado

Observando os modelos do mapeamento sistemático realizado na seção 3 deste trabalho, o modelo LSTM foi utilizado em dois dos seis artigos analisados, e obteve um bom resultado na predição, portanto o algoritmo de predição é no modelo LSTM.

Por se tratar de uma tabela pequena, foi utilizado o modelo mais simples que é o sequencial. O *target* foi a coluna de quantidade de óbitos e as *features* a quantidade de casos novos e a quantidade de doses.

Parâmetros	Valores
Números de camadas	3
Números de nós em cada camada	40, 40
Números de camadas completamente conectadas	1
Número de nós em camadas completamente conectadas	1
Tamanho do lote	5
Épocas	50

Tabela 4.1: Parâmetros usados no modelo de predição LSTM

4.3 Avaliação experimental

O resultado apresenta um *overfitting* dos dados, sendo incapaz de predizer os próximos valores. A média de perda é de 0,035 nos dados de treinamento e o R^2 score na validação é menor que -1 .




Figura 4.1: Gráfico gerado na fase de treinamento da LSTM




Figura 4.2: Gráfico gerado na fase de validação da LSTM



Figura 4.3: Gráfico gerado na fase de predição da LSTM

Conclusão

5.1 Contribuições do trabalho

No contexto da análise dos modelos de predição de óbitos no cenário da Covid-19 a medida que a vacinação ocorre, este trabalho mostrou através do mapeamento sistemático os principais modelos de redes neurais escolhidos para esse contexto, entre eles estão:

- SIRUCQHE (Susceptible - Infected - Removed - Unsusceptible - Contagious - Quarantined - Hospitalized - Extinct) [9];
- SEIAQFR (Susceptible - Exposed - Infected - Asymptomatic - Quarantined - Fatal - Recovered) [5];
- SIR (Susceptible - Infected - Recovered) [4];
- DNN (Fully Connected Deep Neural Network) [3];
- LSTM (Long Short-Term Memory) [2] e [3];
- TM (Transformer Model) [3];
- RNN (Recurrent Neural Network) [2];
- CNN (Convolutional Neural Network) [2];
- ANN (Multi-Layer Perceptron Artificial Neural Network) [7].

Além disso, foi realizado um estudo de caso na região Centro-Oeste brasileiro, evidenciando através de gráficos as curvas de vacinação mensal a partir de janeiro de 2021 até junho de 2022 e os tipos de doses.

Por fim, foi implementado um algoritmo de predição baseado no modelo LSTM, o conjunto de dados que alimenta esse modelo foi retirado do *OpenDataSUS* referente ao Estado de Goiás, e nele contém a quantidade de óbitos, vacinados e casos novos, todos mensalmente. O algoritmo apresentou um overfitting com causa não identificada.

5.2 Trabalhos Futuros

Para um próximo passo melhorar a qualidade do algoritmo de predição utilizando o modelo LSTM e acrescentar mais algoritmos para análise estatística de óbitos.

5.3 Disponibilidade dos Códigos e Dados

Todos os algoritmos criados para este trabalho estão disponíveis no github. E os dados que foram retirados do *OpenDataSUS* são os da Campanha Nacional de Vacinação contra Covid-19, e do Registro de Ocupação Hospitalar COVID-19. Além desses conjuntos de dados também foi retirado uma tabela já pré-processada do site Coronavírus Brasil.

Referências Bibliográficas

- [1] **Ciência de dados, Business Intelligence e Big Data : Conceitos e aplicações.** Appris, 2021.
- [2] AGARWAL, N.; DUTTA, R. **Comparative predictive analysis of mortality rate after covid-19 vaccination using various machine learning approaches.** In: *2022 International Conference on Computer Communication and Informatics (ICCCI)*, p. 01–05, 2022.
- [3] ALKHAMMASH, E. H.; ALGETHAMI, H.; ALSHAHRANI, R.; AHMED, S. H. **Novel prediction model for covid-19 in saudi arabia based on an lstm algorithm.** *Intell. Neuroscience*, 2021, jan 2021.
- [4] CHINCHILLA, R.; YANG, G.; ERDAL, M. K.; COSTA, R. R.; HESPANHA, J. P. **A tale of two doses: Model identification and optimal vaccination for covid-19.** In: *2021 60th IEEE Conference on Decision and Control (CDC)*, p. 3544–3550, 2021.
- [5] DE CARVALHO, K. C.; VICENTE, J. P.; TEIXEIRA, J. P. **Covid-19 time series forecasting – twenty days ahead.** *Procedia Computer Science*, 196:1021–1027, 2022. International Conference on ENTERprise Information Systems / ProjMAN - International Conference on Project MANagement / HCist - International Conference on Health and Social Care Information Systems and Technologies 2021.
- [6] OLIVEIRA, L.; BERRETTA, L.; KUDO, T. **Mapeamento sistemático: Museu em realidade aumentada.** In: *Anais da IX Escola Regional de Informática de Goiás*, p. 1–11, Porto Alegre, RS, Brasil, 2021. SBC.
- [7] RAKSHIT, P.; KUMAR, S.; NOEIAGHDAM, S.; FERNANDEZ-GAMIZ, U.; ALTANJI, M.; SANTRA, S. S. **Modified sir model for covid-19 transmission dynamics: Simulation with case study of uk, us and india.** *Results in Physics*, 40:105855, 2022.
- [8] SCANNAVINO, K. R. F.; NAKAGAWA, E. Y.; FABBRI, S. C. P. F.; FERRARI, F. C. **Revisão Sistemática da Literatura em Engenharia de Software: teoria e prática.** Elsevier, 2017.

- [9] SCARABAGGIO, P.; CARLI, R.; CAVONE, G.; EPICOCO, N.; DOTOLI, M. **Modeling, estimation, and optimal control of anti-covid-19 multi-dose vaccine administration.** In: *2021 IEEE 17th International Conference on Automation Science and Engineering (CASE)*, p. 990–995, 2021.